

Método de la Potencia y PCA

Métodos Numéricos

1 Cuatrimestre 2023

Autovalores y Autovectores

Definición

Sea $A \in \mathbb{R}^{n \times n}$. Un *autovector* de A es un vector no nulo tal que $Ax = \lambda x$, para algún escalar λ . Un escalar λ es denominado *autovalor* de A si existe una solución no trivial x del sistema $Ax = \lambda x$. En este caso, x es llamado *autovector asociado a λ* .

Consideramos:

$$A = \begin{bmatrix} 3 & -2 \\ 1 & 0 \end{bmatrix}, u = \begin{bmatrix} -1 \\ 1 \end{bmatrix}, v = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$Au = \begin{bmatrix} -5 \\ -1 \end{bmatrix}, Av = \begin{bmatrix} 4 \\ 2 \end{bmatrix} = 2 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = 2v$$

Gráficamente.... A sólo estira (o encoge) el vector v .

Autovalores y autovectores

Dada una matriz $A \in \mathbb{R}^{n \times m}$, un vector $\mathbf{x} \in \mathbb{R}^m$ no nulo puede ser paralelo a $A\mathbf{x}$, lo que significa que existe una constante λ tal que $A\mathbf{x} = \lambda\mathbf{x}$.


A todos los \mathbf{x} que cumplen esta propiedad se los denomina autovectores de A y λ su autovalor asociado.

Autovalores y autovectores

Dada una matriz $A \in \mathbb{R}^{n \times m}$, un vector $\mathbf{x} \in \mathbb{R}^m$ no nulo puede ser paralelo a $A\mathbf{x}$, lo que significa que existe una constante λ tal que $A\mathbf{x} = \lambda\mathbf{x}$.

A todos los \mathbf{x} que cumplen esta propiedad se los denomina autovectores de A y λ su autovalor asociado.

Representación gráfica:



En muchos casos, la presencia de autovectores-autovalores puede ser utilizada para encontrar una factorización $A = PDP^{-1}$, donde D es una matriz diagonal.

Intuición

Podemos encontrar una base donde la transformación lineal A se comporta como si fuese diagonal.

Observación

No toda matriz $A \in \mathbb{R}^{n \times n}$ es diagonalizable.

Teorema

Una matriz $A \in \mathbb{R}^{n \times n}$ es diagonalizable sí y solo sí A tiene n autovectores linealmente independientes (las columnas de P).

Más teoremas

Teorema Espectral

Si $A \in \mathbb{R}^{n \times n}$ es simétrica, entonces existe una base ortonormal de autovectores $\{v_1, \dots, v_n\}$ asociados a $\lambda_1, \dots, \lambda_n$.

Consecuencia: Existe P , y $P^{-1} = P^t$. Luego, $A = PDP^t$.

Teorema

Sea $A \in \mathbb{R}^{m \times n}$. Luego, si λ es autovalor de $A^T A$, con autovector v entonces λ es también autovalor de AA^T con autovector Av .

Cálculo de autovalores/autovectores

- Podemos considerar el Método de la Potencia para calcular λ_1 y v_1 .

1. MetodoPotencia($B, x_0, niter$)
2. $v \leftarrow x_0$.
3. Para $i = 1, \dots, niter$
4. $v \leftarrow \frac{Bv}{||Bv||}$
5. Fin Para
6. $\lambda \leftarrow v^t B v$
7. Devolver λ, v .

Cálculo de autovalores/autovectores

Una vez que tenemos λ_1 y v_1 , como seguimos?

Deflación

Sea $B \in \mathbb{R}^{n \times n}$ una matriz con autovalores distintos

$|\lambda_1| > |\lambda_2| > \dots > |\lambda_n|$ y una base ortonormal de autovectores.

Entonces, la matriz $B - \lambda_1 v_1 v_1^t$ tiene autovalores $0, \lambda_2, \dots, \lambda_n$ con autovectores asociados v_1, \dots, v_n .

- ▶ $(B - \lambda_1 v_1 v_1^t)v_1 = Bv_1 - \lambda_1 v_1(v_1^t v_1) = \lambda_1 v_1 - \lambda_1 v_1 = 0v_1$.
- ▶ $(B - \lambda_1 v_1 v_1^t)v_i = Bv_i - \lambda_1 v_1(v_1^t v_i) = \lambda_i v_i$.

Observación


En nuestro caso, no hace falta que todos los autovalores tengan magnitudes distintas.

Análisis de Componentes Principales

Ejemplo datos en \mathbb{R}^2

Sean $x^{(1)}, x^{(2)}, \dots, x^{(n)}$ una secuencia de n datos, con $x^{(i)} \in \mathbb{R}^2$.

$$X = \begin{bmatrix} x^{(1)t} \\ x^{(2)t} \\ x^{(3)t} \\ x^{(4)t} \\ x^{(5)t} \\ x^{(6)t} \\ \vdots \\ x^{(n)t} \end{bmatrix} = \begin{bmatrix} 26,4320 & 27,7740 \\ 26,8846 & 26,5631 \\ 23,3309 & 26,6983 \\ 30,6387 & 31,5619 \\ 30,5171 & 30,8993 \\ 45,6364 & 36,6035 \\ \vdots & \vdots \\ 16,0650 & 24,0210 \end{bmatrix}$$



Análisis de Componentes Principales


Ejemplo datos en \mathbb{R}^2

$$X = \begin{bmatrix} 26,4320 & 27,7740 \\ 26,8846 & 26,5631 \\ 23,3309 & 26,6983 \\ 30,6387 & 31,5619 \\ 30,5171 & 30,8993 \\ 45,6364 & 36,6035 \\ \vdots & \vdots \\ 16,0650 & 24,0210 \end{bmatrix}$$

Media:

$$\mu = \frac{1}{n}(x^{(1)} + \dots + x^{(n)})$$

$$\mu = (29,3623, 29,7148)$$



Varianza de una variable x_k : Medida para la dispersión de los datos.

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_k^{(i)} - \mu_k)^2$$

$$\sigma_{x_1}^2 = 66,2134, \quad \sigma_{x_2}^2 = 12,5491$$

Análisis de Componentes Principales

Ejemplo datos en \mathbb{R}^2 - Covarianza

Covarianza: Medida de cuánto dos variables varían de forma similar. Variables con mayor covarianza inducen la presencia de cierta dependencia o relación.

$$\sigma_{x_j x_k} = \frac{1}{n-1} \sum_{i=1}^n (x_j^{(i)} - \mu_j)(x_k^{(i)} - \mu_k)$$

Análisis de Componentes Principales

Ejemplo datos en \mathbb{R}^2 - Covarianza

Dadas n observaciones de dos variables x_1 , x_2 , y $v = (1, \dots, 1)^t$:

$$\sigma_{x_1 x_2} = \frac{1}{n-1} \sum_{i=1}^n (x_1^{(i)} - \mu_1)(x_2^{(i)} - \mu_2) = \frac{1}{n-1} (x_2 - \mu_2 v)^t (x_1 - \mu_1 v)$$

Matriz de Covarianza:

$$X = \begin{bmatrix} 26,4320 - \mu_1 & 27,7740 - \mu_2 \\ 26,8846 - \mu_1 & 26,5631 - \mu_2 \\ 23,3309 - \mu_1 & 26,6983 - \mu_2 \\ 30,6387 - \mu_1 & 31,5619 - \mu_2 \\ 30,5171 - \mu_1 & 30,8993 - \mu_2 \\ 45,6364 - \mu_1 & 36,6035 - \mu_2 \\ \vdots & \vdots \\ 16,0650 - \mu_1 & 24,0210 - \mu_2 \end{bmatrix} \quad M_X = \frac{1}{n-1} X^t X = \begin{bmatrix} \sigma_{x_1 x_1} & \sigma_{x_1 x_2} \\ \sigma_{x_1 x_2} & \sigma_{x_2 x_2} \end{bmatrix}$$
$$= \begin{bmatrix} \sigma_{x_1}^2 & \sigma_{x_1 x_2} \\ \sigma_{x_1 x_2} & \sigma_{x_2}^2 \end{bmatrix}$$
$$M_X = \begin{bmatrix} 66,2134 & 27,1263 \\ 27,1263 & 12,5491 \end{bmatrix}$$

¿Cómo expresar mejor nuestros datos?

Objetivo

Buscamos una transformación de los datos que disminuya la redundancia (es decir, disminuir la covarianza).


Alternativa y equivalentemente: encontrar direcciones ortogonales que maximicen la varianza de nuestros datos

- ▶ Cambio de base: $\hat{X}^t = PX^t$.
- ▶ Cómo podemos hacerlo? Diagonalizar la matriz de covarianza. Esta matriz tiene la varianza de cada variable en la diagonal, y la covarianza en las restantes posiciones. Luego, al diagonalizar buscamos variables que tengan covarianza cero entre sí y la mayor varianza posible.
- ▶ La matriz de covarianza $M_x = \frac{1}{n-1}X^tX$ es simétrica y semidefinida positiva.
- ▶ Si quieren ver una demo, *Pattern Recognition and Machine Learning* de Christopher Bishop

¿Cómo expresar mejor nuestros datos?

Volvemos al ejemplo

$$\begin{aligned} M_X &= \begin{bmatrix} 66,2134 & 27,1263 \\ 27,1263 & 12,5491 \end{bmatrix} \\ &= \underbrace{\begin{bmatrix} 0,9228 & -0,3852 \\ 0,3852 & 0,9228 \end{bmatrix}}_V \underbrace{\begin{bmatrix} 77,5362 & 0 \\ 0 & 1,2263 \end{bmatrix}}_{D=M_{\hat{X}}} \underbrace{\begin{bmatrix} 0,9228 & 0,3852 \\ -0,3852 & 0,9228 \end{bmatrix}}_{V^t} \end{aligned}$$



Análisis de Componentes Principales

Resumen hasta acá

- ▶ Tenemos n muestras de m variables.
- ▶ Calculamos el vector μ que contiene la media de cada de una las variables.
- ▶ Construimos la matriz $X \in \mathbb{R}^{n \times m}$ donde cada muestra corresponde a una fila de X y tienen media cero (i.e., $X_i := (x^{(i)} - \mu)$).
- ▶ Diagonalizamos la matriz de covarianzas $M_X = \frac{X^t X}{n-1}$. La matriz V (ortogonal) contiene los autovectores de M_X .

Propiedades del cambio de base

- ▶ Disminuye redundancias.
- ▶ El cambio de base $\hat{X}^t = P X^t = V^t X^t$ asigna a cada muestra un nuevo *nombre* mediante un cambio de coordenadas.
- ▶ Las columnas de V (autovectores de M_X) son las componentes principales de los datos.
- ▶ En caso de m grande, es posible tomar sólo un subconjunto de las componentes principales para estudiar (i.e., aquellas que capturen mayor proporción de la varianza de los datos).